Постобработка OCR паспорта РФ

Я реализовала постобработку с приоритетом отсутствия ошибочных принятий, даже ценой большого числа отказов. Решение работает на CPU без интернета и сторонних библиотек. Оно проверяет распознанные значения и отклоняет сомнительные документы, не пытаясь угадывать недостающие символы.

Сначала я восстановила порядок строк по координатам и добавила проверку полноты полей по геометрии рамок. Для каждого символа во всех визуальных полях и обеих строках MRZ установила минимальную уверенность 0,99. Из визуальных значений формируются ожидаемые строки MRZ с кодировкой «модернизированный клер» и контрольными цифрами; требуется полное совпадение с распознанной зоной. Отсутствующее отчество допускается только при согласии с MRZ. Нормализация затрагивает регистр и повторные пробелы, но сохраняет пунктуацию и букву Ё.

Дополнительно я проверила формат серии и номера, наличие кода подразделения в справочнике DaData и календарную действительность паспорта на 01.10.2026. Учитываются возраст при выдаче, замены в 20 и 45 лет и 90-дневный переходный срок. Название органа выдачи не заменяется по справочнику: одному коду могут соответствовать разные исторические наименования. Реестровый статус документа по имеющимся данным проверить нельзя.

При анализе я обнаружила, что совпадение визуальной зоны и MRZ не исключает ошибку: одинаковое неверное значение может присутствовать в обеих зонах. У mobile_v2 также встречаются ошибки при завышенной уверенности. Поэтому итоговый вариант принимает только документы из mobile. Для web и mobile_v2 возвращается reject. Это ограничивает покрытие, но расширение источников в проверенных вариантах приводило к ошибочным принятиям.

Размеченные данные я первоначально разделила на 2000 документов для разработки и 1000 для проверки с seed=20261001. Первый вариант допустил две ошибки на отложенной части, после чего я усилила проверки уверенности. Таким образом, отложенная часть использовалась при переработке, и итоговая оценка уже не является независимой. На повторной проверке приняты 30 документов из первой части и 15 из второй; все десять полей совпали с разметкой. Всего на train принято 45 из 3000 документов, ошибок — 0. Календарно недействительных среди принятых также нет. Дополнительно прошли 19 модульных тестов.

На test итоговый вариант принимает 45 из 2000 документов и отклоняет 1955; покрытие составляет 2,25%. Мой прогноз — 45 принятых документов, 0 ошибочных. Число принятых уже известно из запуска, а прогноз ошибок основан на нулевой наблюдаемой частоте в размеченных данных. Из-за малого числа принятых примеров и повторного использования проверочной выборки это не гарантия: фактические ошибки на test можно установить только по закрытой разметке. Для обоснованного увеличения покрытия нужна новая независимая выборка.

При реализации я использовала алгоритм MRZ из приложения 24 к приказу МВД № 773, правила срока действия из пункта 24 постановления Правительства РФ № 2267 и предоставленный справочник DaData (CC BY-SA 4.0).