Постобработка OCR паспорта РФ

1. Приоритет решения

Основная цель - не принимать документы с ошибками, даже ценой большого числа отказов. Итоговый строгий вариант на всей доступной разметке принимает 45 документов из 3000, все 10 полей каждого из них совпадают с разметкой. Ошибочных принятий и календарно недействительных принятых паспортов на этой проверке нет. Для test сформированы 2000 ответов: 45 accept и 1955 reject.

Прогноз для test: 45 принятых документов, 0 ошибочных. Число принятых уже известно из запуска. Ноль ошибок - эмпирический точечный прогноз по доступной разметке, а не подтверждённый результат на test: разметка test отсутствует. Покрытие test составляет 2,25%.

2. Алгоритм

Решение написано на Python 3.9+ и использует только стандартную библиотеку. Работает на CPU, без сети, обученных весов и доступа к train_labels.jsonl во время обработки. Порядок ответов совпадает с порядком входных документов. У accept выдаются все 10 полей; у reject поля не выдаются.

1. Строки каждого визуального поля сортируются по координатам. Проверяются пропуски строк по верхнему/нижнему отступу и межстрочным промежуткам относительно высоты строки. Размер массива char_conf должен совпадать с длиной исходной строки. Нормализуются регистр и повторные пробелы; точки, дефисы и буква Ё сохраняются.

2. Для каждого символа во всех 10 визуальных полях и обеих строках MRZ требуется char_conf не ниже 0,99. Низкая уверенность даже в числовом поле, совпадающем с MRZ, приводит к отказу. Проверяются наличие, длина и диапазон оценок MRZ. Средняя уверенность по полю не заменяет посимвольную проверку.

3. Из визуальных значений строятся обе ожидаемые строки MRZ. Используются кодировка «модернизированный клер», перенос четвёртой цифры серии в дополнительную область, контрольные цифры с весами 7/3/1 и итоговая контрольная цифра. Требуется полное совпадение строк. Неизвестные значения не восстанавливаются догадками. Отсутствующее отчество допускается только при согласии с MRZ.

4. Проверяются формат серии/номера, существование кода подразделения в исходном справочнике DaData и календарные ограничения. Название органа не подменяется по коду: один код может иметь несколько исторических наименований, отличающихся от разметки. Справочник и атрибуция CC BY-SA 4.0 сохранены без изменений.

5. Даты должны существовать в календаре; паспорт не может быть выдан в будущем или до 14-летия. Срок действия проверяется на 01.10.2026 с учётом замен в 20/45 лет и 90-дневного переходного срока. Утрату, отзыв, смерть владельца и замену документа без доступа к реестрам определить нельзя. Здесь проверяется только календарная действительность.

6. Область автоматического принятия ограничена источником mobile. На web наблюдались согласованные ошибки двух зон, на mobile_v2 - ошибки при завышенной уверенности. Эти источники направляются на пересъёмку/перепроверку. Ограничение источника - консервативная политика по наблюдениям, а не доказательство отсутствия ошибок у mobile.

3. Проверка и результаты

Первоначальное разбиение: 2000 development и 1000 holdout, случайная перестановка с seed=20261001. Список идентификаторов разбиения сохранён локально. После неудачной первоначальной проверки правила были усилены, поэтому прежний holdout уже использован при переработке. Ниже приведена повторная проверка, которую нельзя считать новой независимой валидацией.

Выборка	Всего	Принято	С ошибкой в полях	Доля принятых
Development	2000	30	0	1,50%
Прежний holdout, повторно	1000	15	0	1,50%
Весь train	3000	45	0	1,50%
Test	2000	45	неизвестно	2,25%

Исходный evaluate.py подтверждает: 45 принятых верно, 0 принятых с ошибкой. Проверка календарной действительности по значениям разметки также даёт 0 недействительных среди принятых. Локальная дополнительная проверка контролирует отсутствие ошибочных и календарно недействительных принятий на размеченных данных.

Выполнены 19 модульных тестов: известные примеры контрольных цифр, расположение цифры серии, повреждение MRZ, несовпадение зон, потеря строк, отсутствие отчества, границы срока действия, низкая уверенность в числовом поле, низкая/отсутствующая/некорректная уверенность MRZ и включительная граница 0,99. Проверена схема ответов, уникальность всех 2000 doc_id и сохранение порядка.

4. Что выяснилось и почему пришлось сократить покрытие

Первый вариант проверял уверенность только у части визуальных полей и полагался на совпадение остальных полей с MRZ. Он принимал 307 test-документов, но на 1000 отложенных примерах допустил 2 ошибочных принятия. Это противоречило приоритету задания; такой результат не оставлен итоговым.

Совпадение зон не означает независимого подтверждения: одинаковая ошибка может присутствовать в обеих. Полное применение порога 0,99 отсеивает прежние ошибочные принятия. Вариант с разрешённым web при том же пороге также показал ошибку на повторной проверке, поэтому расширение источников не принято. Списки конкретных ошибочных doc_id, подстановка разметки и запоминание персональных значений не используются.

Политика сознательно предпочитает отказ сомнительному принятию. Увеличение покрытия не считается улучшением, если на доступной проверке появляются дорогие ошибки. При этом 2,25% покрытия - достигнутый результат, а не доказанный максимум: для безопасного расширения нужны новые данные и независимая проверка.

5. Прогноз и ограничения

Прогноз: 45 принятых, 0 ошибочных на test. Его основание - нулевая наблюдаемая частота ошибок у принятой группы на размеченных данных. Однако 45 принятых примеров мало, а данные уже использовались при выборе правил. Поэтому наблюдаемый ноль не доказывает нулевой риск; корректную независимую доверительную гарантию по этой повторной проверке дать нельзя. Фактическое число ошибок на test будет известно только после сверки с закрытой разметкой.

Для дальнейшего развития нужны свежая отложенная выборка, отдельная калибровка по источникам и независимая перепроверка изображения для сомнительных полей. До такой проверки расширять автоматическое принятие не следует. Остальные документы возвращаются как reject.

Воспроизводимость и источники

Запуск: python postprocess.py data/test_predictions.jsonl answers.jsonl. Для сверки на train: python postprocess.py data/train_predictions.jsonl train_answers.jsonl, затем python evaluate.py train_answers.jsonl data/train_labels.jsonl. Входные данные и evaluate.py предоставлены в материалах задания. Полные метрики, тесты и диагностика сохранены локально.

- MRZ: приказ МВД № 773, приложение 24, https://pvsmvd.ru/media/decrees/060/ec2a3b45.pdf

- Срок действия: постановление Правительства РФ № 2267, пункт 24, https://www.garant.ru/products/ipo/prime/doc/408223437/